

Hash e Índices Bitmap

98H00-04 - Infraestrutura para Gestão de Dados

Prof. Msc. Eduardo Arruda eduardo.arruda@pucrs.br

Índices Hash

- Utiliza técnica de hashing para distribuir registros em um espaço de distribuição
- Emprega uma função hash (de "espalhamento") para organizar registros em um data file ou para organizar chaves de busca em um índice
 - A função hash é aplicada sobre o valor da chave de busca
 - Seu resultado indicará em que *bucket* (depósito) o registro ou entrada de índice deve ser armazenado (na inserção) ou está localizado (em buscas)
- Presta-se somente para buscas por igualdade
- Sensível à distribuição dos dados
 - Caso seja escolhida uma função hash inadequada, os registros podem se concentrar em poucos buckets e gerar muito overflow

Exemplo de função de hash para chaves numéricas

- Chave = $(x_1 x_2 ... x_n)$, sequência de caracteres n bits
- Para endereçar 2^b buckets:

h(k) = b bits menos significativos da chave k

- Exemplo: para endereçar 8 *buckets*
 - Chave k = 1971 = 11110110**011**
 - h(k) = 3 bits menos significativos de 1971 = 011 = 3
 - o registro será inserido ou está localizado no bucket 3

- Chave ='x₁ x₂ ... x_n", sequência de caracteres de n Bytes
- Para endereçar b buckets:

$$h(k) = soma (x_1 x_2 ... x_n) mod b$$

- Exemplo: para endereçar 9 *buckets*
 - Chave = 'maria' a=1, b=2, ..., z=26
 - $h(k) = (13+1+18+9+1) \mod 9 = 6$
 - o registro será inserido ou está localizado no bucket 6

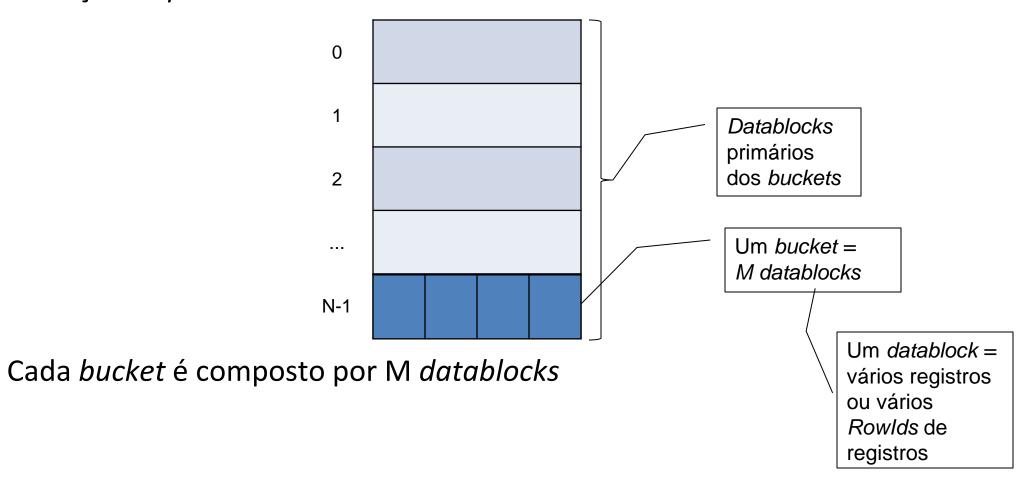
Qualidade da função hash

- Uma função *hash* é boa se o número esperado de chavespor *bucket* é o mesmo para todos os *buckets*, ou seja, a função gera uma distribuição homogênea
- Exemplo:
 - Se para sequências de caracteres escolhemos como função *hash* o número da primeira letra:

$$A = 1, ..., Z = 26$$

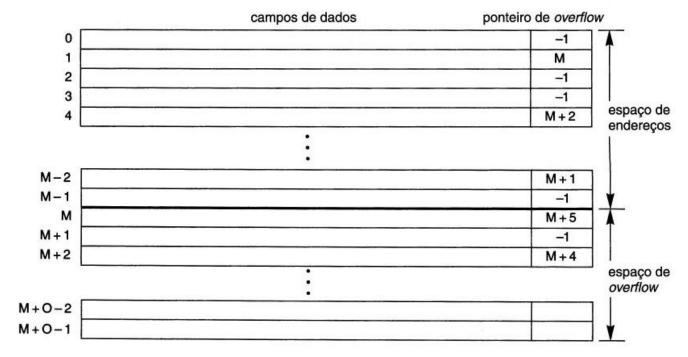
essa função não é boa. Por quê???

• Alocação sequencial de N buckets



Overflow de buckets

- O espaço é dividido estaticamente em espaço de endereços e espaço de *overflow*
- Quando a função não é adequada, a multiplicação de overflow irá prejudicar o desempenho



• ponteiro null = -1.

• o ponteiro de overflow se refere à posição do próximo registro na lista encadeada



Hashing estático

- O número de *buckets* deve ser dimensionado de acordo com o número esperado de linhas na tabela
 - buckets = (linhas / linhas_por_bucket) * fator_ajuste (ex.: 1,25)
- Dentro de 1 bucket devemos manter as chaves ordenadas?
 Sim, se a frequência de inserção/deleção é baixa.

$$h(a) = 1$$

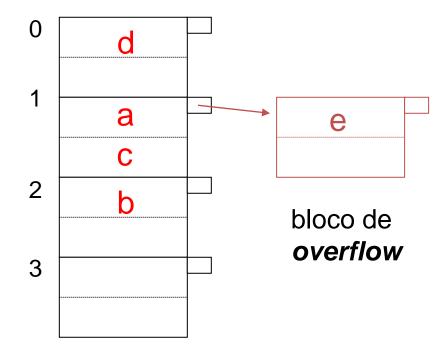
$$h(b) = 2$$

$$h(c) = 1$$

$$h(d) = 0$$

$$h(e) = 1$$

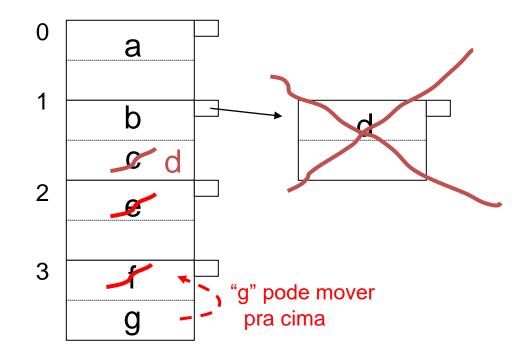
Inserção



Exclusão

e f

C



Se o número de blocos de overflow fica significativo

Busca vai ficando "sequencial"

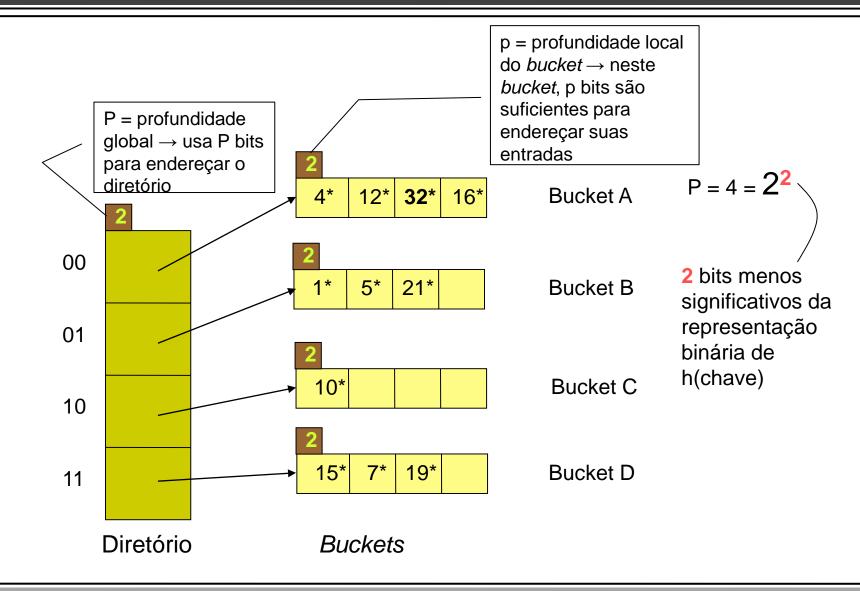
Perda de desempenho

Regra geral

- Tentar manter o espaço utilizado entre 50% e 80%
 Utilização = # chaves usadas / # total espaços
 - Se < 50%, desperdiça espaço
 - Se > 80%, overflow pode ser significativo
- Deve-se ter:
 - Uma função *hash* boa
 - Número de entradas por bucket bem dimensionado

Hashing extensível

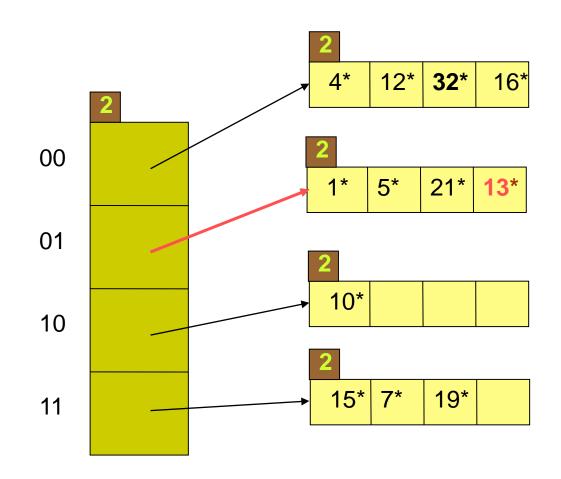
- É empregada função hash que gera inteiros binários com b bits
- i bits do início do valor do *hash* são usados como índice para uma tabela auxiliar de endereçamento dos *buckets*
- O valor de i cresce ou decresce com o aumento ou diminuição do número de registros
- O espaço de endereçamento possui um inteiro P, chamado "profundidade global", que define o número de bits máximo utilizado para endereçamento de buckets
- Cada bucket j possui um inteiro p_j, chamado "profundidade local", que define o número de bits utilizado para endereçamento daquele bucket



Algoritmo de inserção em hashing extensível

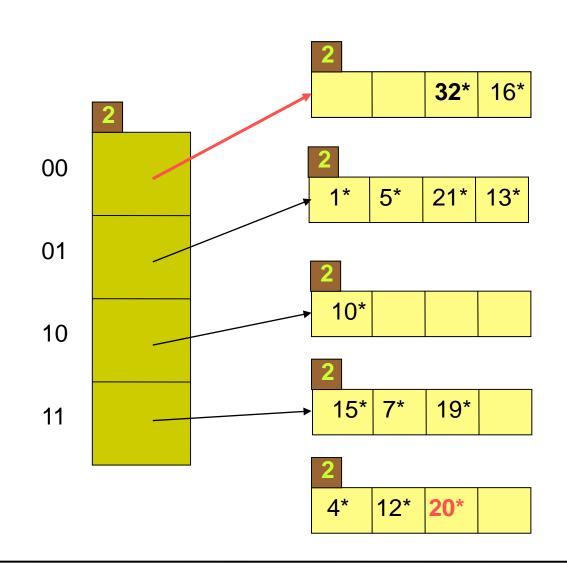
- Aplica-se a função hash e considera-se P bits, localizando a entrada no diretório
- Se não houver *overflow*, insere
- Se houver overflow, verifica:
 - Se p < P, então p = p + 1, aloca-se um novo bucket ("bucket ïrmão" p bits são iguais) e redistribui-se as entradas entre estes dois buckets, considerando-se p bits
 - Se p = P, então duplica-se o diretório, fazendo P = P + 1, faz-se todas as demais novas entradas do diretório apontarem para os mesmos buckets de suas "entradas irmãs", aloca-se um novo bucket e redistribui-se as entradas entre estes dois buckets considerando-se P bits
 - Os buckets que foram objeto do overflow serão os únicos com p = P

Inserção sem overflow



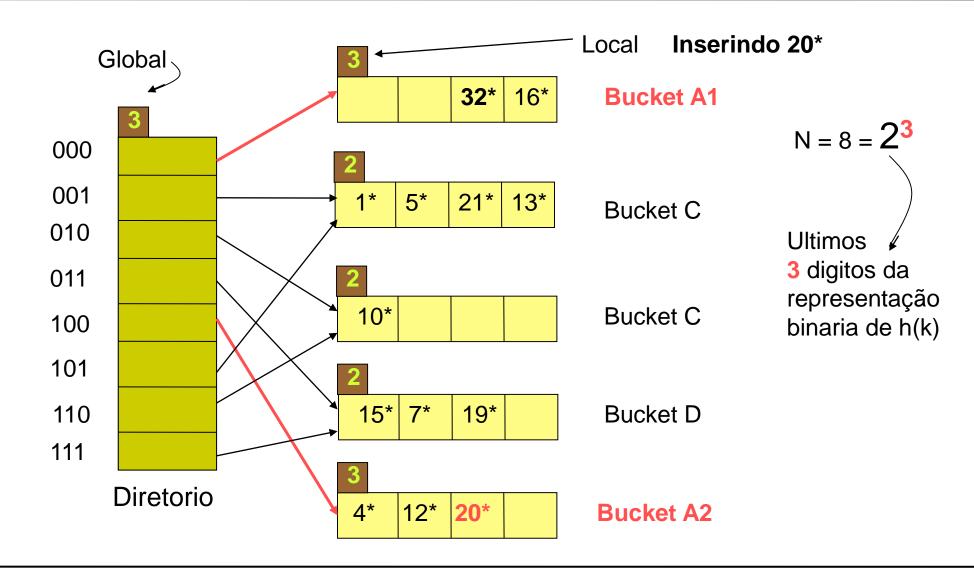
Inserindo 13*

Inserção com *overflow*



Inserindo 20*

Inserção com *overflow* e duplicação de diretório



Hashing linear

- Permite a expansão ou redução do número de buckets sem a necessidade de um diretório
- Trabalha com famílias de funções hash:
 - Supondo que se inicie com h(k) = k mod M, onde M é o número de buckets
 - Os buckets são inicialmente endereçados de 0 a M-1

Algoritmo de inserção em hashing linear

- Quando ocorrer um overflow em algum bucket (qualquer bucket), cria-se mais um bucket ao final do espaço de endereçamento
 - A primeira vez será o bucket M
- As entradas do bucket 0 são redistribuídas entre o bucket 0 e o bucket M utilizando a função
 - $h(k) = k \mod 2M$
 - Se o overflow tiver ocorrido em um bucket diferente do bucket 0, é criado um bloco de overflow para ele
 - No próximo overflow, será criado o bucket M+1 e as entradas do bucket 1 são redistribuídas entre o bucket 1 e o bucket M + 1
 - O algoritmo segue nesta rodada até ser criado o bucket 2M − 1
- No próximo overflow, passar-se-á a utilizar a função
 - h(k) = k mod **3**M

e o ciclo se repetirá até a criação do *bucket* 3M - 1

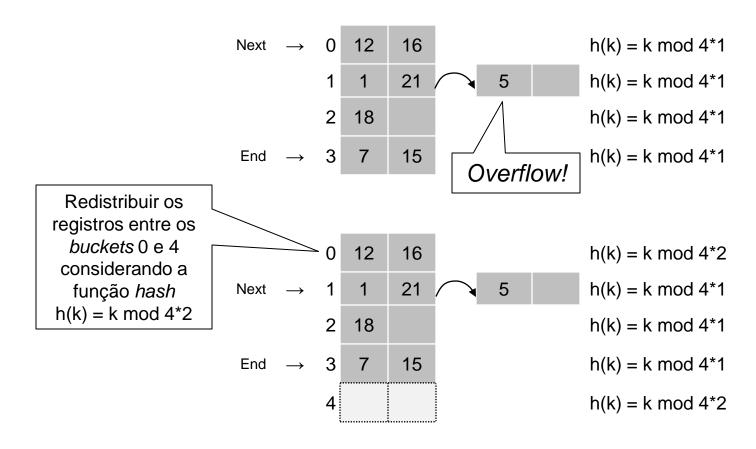
- Considere uma estrutura de acesso em hash linear com inicialmente 4 buckets com capacidade para 2 registros em cada bucket
- Considere a inserção dos registros com valores de chave de busca 1, 7, 12, 15, 16, 18 e 21
- Considere que esta estrutura em *hash* utiliza a seguinte família de funções *hash*
 - $h(k) = k \mod 4*1 \rightarrow h(k) = k \mod 4*2 \rightarrow h(k) = k \mod 4*3 \rightarrow ...$
- A estrutura hash estaria assim populada inicialmente

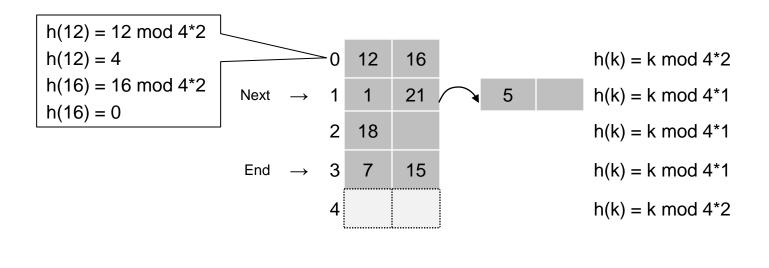
| Next | \rightarrow | 0 | 12 | 16 |
|------|---------------|---|----|----|
| | | 1 | 1 | 21 |
| | | 2 | 18 | |
| End | \rightarrow | 3 | 7 | 15 |

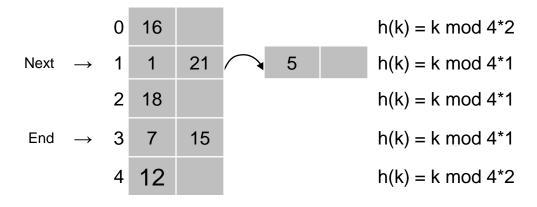
$$h(k) = k \mod 4*1$$

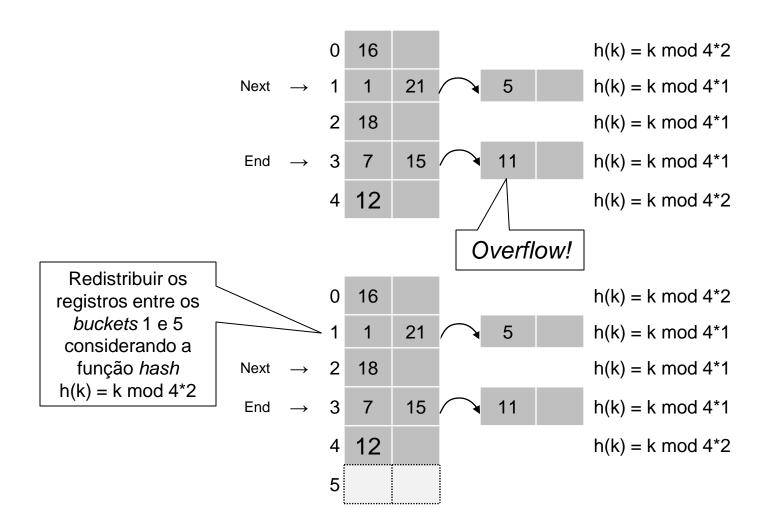
 $h(k) = k \mod 4*1$
 $h(k) = k \mod 4*1$
 $h(k) = k \mod 4*1$

Após a inserção do registro com chave de busca $5 \rightarrow 5 \mod 4 = 1$

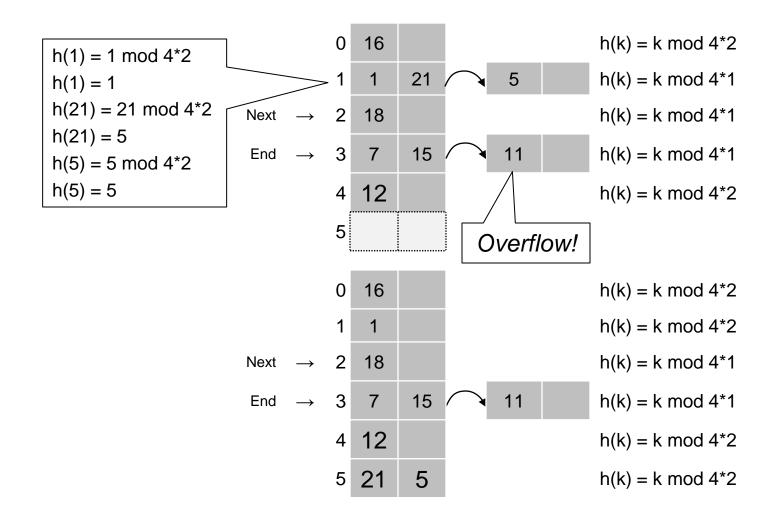


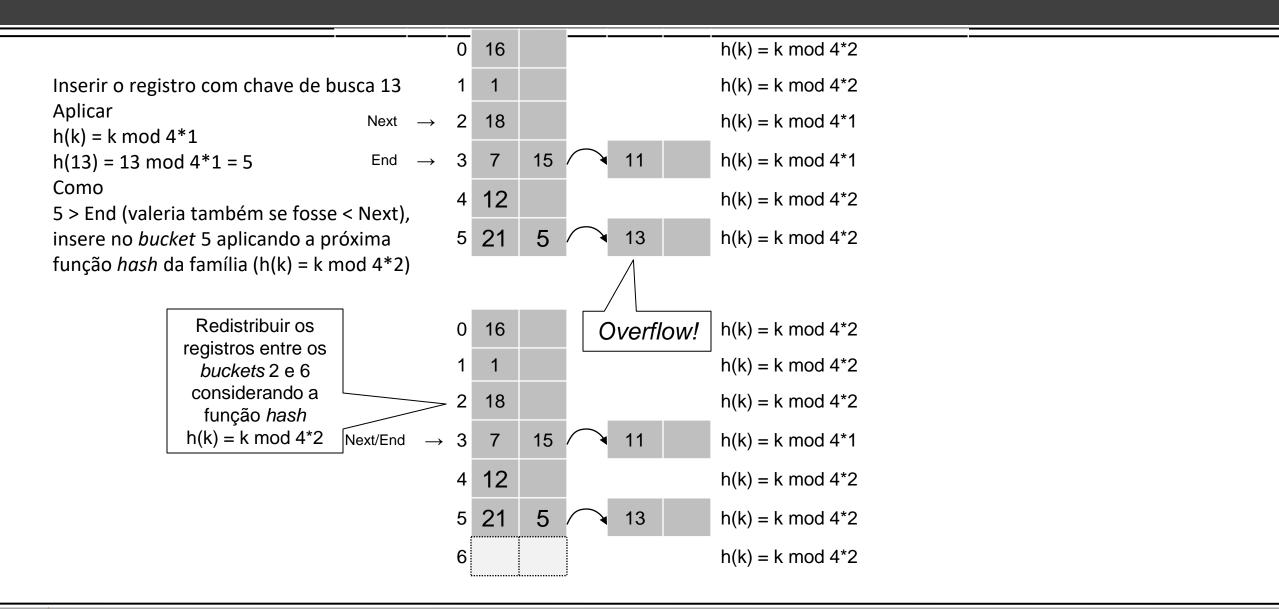


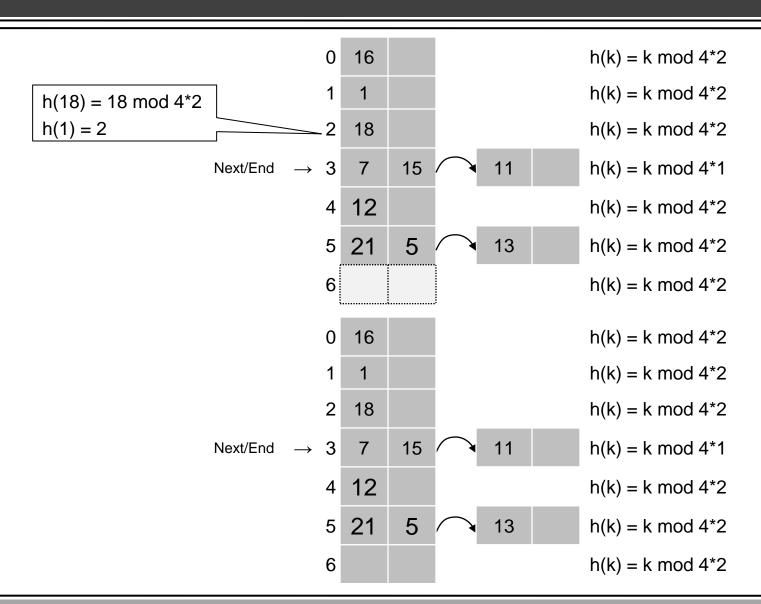


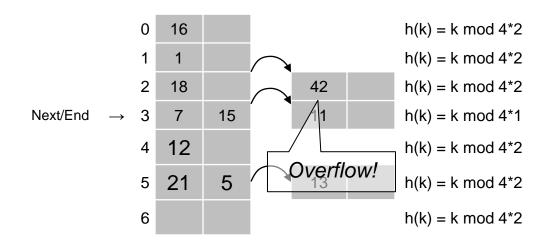


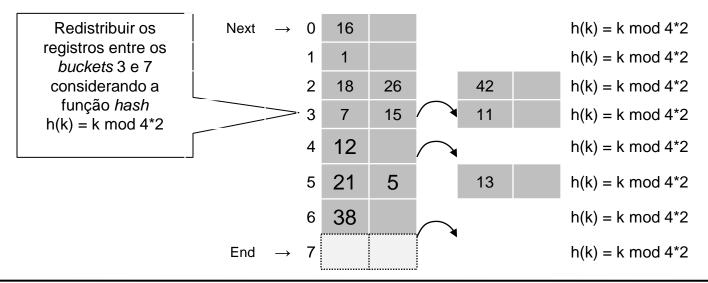
Inserir o registro com chave de busca 11
Aplicar
h(k) = k mod 4*1
h(11) = 11 mod 4*1 = 3
Como
Next < 3 < End, insere no
bucket 3 sem aplicar a próxima
função hash da família











Inserir os registros com chaves de busca 26, 38 e 42

Aplicar

 $h(k) = k \mod 4*1$

h(26) = 2

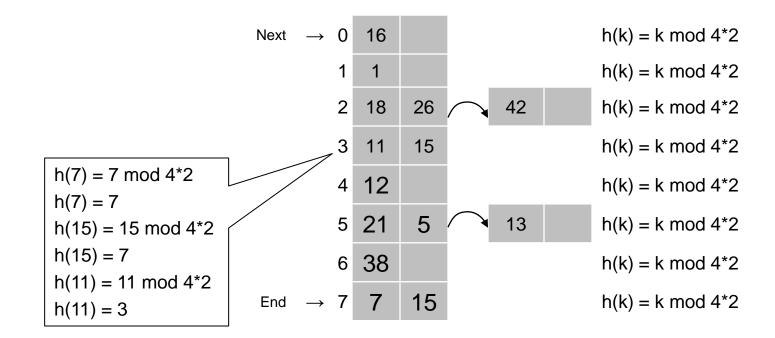
h(38) = 6

h(42) = 2

Como

2 < Next, insere no bucket 2 aplicando a próxima função hash da família (h(k) = k mod 4*2)

- Um ciclo de crescimento do espaço de endereçamento do *hash* foi concluído
 - O número de *buckets* foi dobrado



Índices bitmap

- Um índice bitmap é um mapa de bits para cada um dos valores diferentes da chave, correspondendo às linhas da tabela (registros)
- Se a linha possui aquele valor de chave, no bitmap daquele valor o seu bit será 1
- Índices bitmap se prestam à execução eficiente de operações lógicas (and ou or) entre condições utilizadas no where
- Linhas que não satisfazem a expressão são rapidamente eliminadas o que pode aumentar muito o desempenho das consultas

| Tabela de Clientes | | | | |
|--------------------|--------------|----------|------|-------------|
| Cliente | Estado Civil | REGIÃO | Sexo | Nivel Renda |
| 101 | solteiro | SUL | M | Α |
| 102 | casado | SUDESTE | F | В |
| 103 | casado | SUDESTE | M | С |
| 104 | divorciado | NORDESTE | M | Α |
| 105 | Solteiro | SUL | F | В |
| 106 | casado | SUL | F | Α |
| | | | | |

| REGIÃO='SUL' | REGIÃO=NORDESTE | REGIÃO='SUDESTE' | | |
|---------------------------|-----------------|------------------|--|--|
| 1 | 0 | 0 | | |
| 0 | 0 | 1 | | |
| 0 | 0 | 1 | | |
| 0 | 1 | 0 | | |
| 1 | 0 | 0 | | |
| 1 | 0 | 0 | | |
| Índice Bitmap para Região | | | | |

| NIVE | _RENDA='A' | NIVEL_RENDA='B' | NIVEL_RENDA='C' | | | |
|------|-----------------------------------|-----------------|-----------------|--|--|--|
| 1 | | 0 | 0 | | | |
| 0 | | 1 | 0 | | | |
| 0 | | 0 | 1 | | | |
| 1 | | 0 | 0 | | | |
| 0 | | 1 | 0 | | | |
| 1 | | 0 | 0 | | | |
| ĺnd | Índice Bitmap para Nível de Renda | | | | | |

Índice bitmap

Benefícios

- Redução de espaço para armazenamento do índice se valores não têm muita dispersão
- Redução do tempo de resposta em consultas que utilizam operações complexas de seleção

Quando Usar

- Aplicações de data warehousing
- Consultas com operadores lógicos (and, or, in especialmente) e operações de igualdade
- Colunas com baixa cardinalidade (diversidade de valores)

Índice *bitmap*

- Quando não usar
 - Não é adequado para sistemas de OLTP (Online Transaction Processing)
 - Devido ao alto custo de atualização do índice
 - Não é adequado para consultas com operadores diferentes de "="
 - Colunas com grande cardinalidade (colunas com valores únicos)

Dúvidas?

